

Universidad de la República

Facultad de Ingeniería

Modelos Estadísticos para la clasificación y regresión

Entrega 1 — Obligatorio

Integrantes del grupo

Nombre	Cédula
Facundo Leite	5.185.744-2
Nicolas Martinez	5.432.556-7
Valentina Berón	5.541.264-0

Código del trabajo: <https://github.com/facundo7801/obligatorio1-modest.git>

Profesores:

María Inés Fariello

Gonzalo Cameto

Montevideo, Uruguay

Octubre de 2026

1. Problema 1

1.1. Simulación de una muestra

Se considera la densidad

$$f_X(x; \theta) = \frac{1}{2}(1 + \theta x), \quad -1 \leq x \leq 1, \quad -1 \leq \theta \leq 1,$$

y se desea simular una muestra tomando $\theta = -1/3$. En este caso,

$$f_X(x) = \frac{1}{2} \left(1 - \frac{x}{3}\right).$$

Para generar la muestra se utilizó el método de aceptación-rechazo, tomando como densidad propuesta una distribución uniforme en $[-1, 1]$:

$$g(x) = \frac{1}{2}.$$

La constante utilizada es $M = 4/3$, por lo que un candidato $x \sim U(-1, 1)$ se acepta si

$$u \leq \frac{f_X(x)}{Mg(x)} = \frac{3}{4} \left(1 - \frac{x}{3}\right), \quad u \sim U(0, 1).$$

El procedimiento se repite hasta obtener n observaciones aceptadas.

Para una muestra de tamaño 10 se obtuvo, por ejemplo,

$$x = (0,0523, -0,7548, -0,7058, -0,3231, 0,0924, 0,2595, \\ 0,7691, -0,1610, 0,3569, -0,1851).$$

1.2. Estimador de máxima verosimilitud

Para una muestra $x_1, \dots, x_n$, la función de verosimilitud es

$$V_n(\theta) = \prod_{i=1}^n f_X(x_i; \theta) = \frac{1}{2^n} \prod_{i=1}^n (1 + \theta x_i).$$

Para evitar trabajar directamente con el producto se utilizó el negativo del logaritmo de la verosimilitud:

$$\ell_n(\theta) = -\log V_n(\theta) = n \log(2) - \sum_{i=1}^n \log(1 + \theta x_i).$$

El estimador de máxima verosimilitud se obtiene minimizando esta función en $[-1, 1]$:

$$\hat{\theta} = \arg \min_{-1 \leq \theta \leq 1} \ell_n(\theta).$$

Para realizar la minimización numérica se utilizó el algoritmo de *Golden Search*.

Para la muestra de tamaño 10 obtenida anteriormente se obtuvo

$$\hat{\theta} = -0,2964.$$

1.3. Evaluación del estimador para muestras de tamaño 10

Se generaron 50 muestras independientes de tamaño 10. Para cada muestra se calculó el estimador $\hat{\theta}$ mediante el procedimiento anterior.

Tomando como valor verdadero $\theta = -1/3$, SE, el sesgo y la varianza:

Los resultados obtenidos fueron:

Cuadro 1: Resultados para muestras de tamaño 10.

Cantidad	Tamaño	θ verdadero	$\bar{\hat{\theta}}$	Sesgo	Varianza	MSE
50	10	-0,3333	-0,2949	0,0384	0,2166	0,2181
50	100	-0,3333	-0,3369	-0,0036	0,0243	0,0243
50	1000	-0,3333	-0,3290	0,0044	0,0018	0,0018

Al aumentar el tamaño de la muestra, se observa una disminución considerable de la varianza del estimador y, en consecuencia, del MSE. Además, el sesgo se aproxima a cero. Esto indica que las estimaciones de $\hat{\theta}$ se concentran cada vez más alrededor del verdadero valor $\theta = -1/3$. Para $n = 100$ y $n = 1000$, el término Sesgo² es muy pequeño, por lo que el MSE coincide con la varianza al redondear a cuatro decimales.

2. Problema 2: Regresión en el Conjunto de Datos “Boston Housing”

2.1. Datos y método.

El objetivo es predecir el valor mediano de las viviendas (MEDV) a partir de los 13 atributos disponibles, entre ellos CRIM, RM y LSTAT. Son 506 viviendas, 13 atributos y ningún valor faltante. MEDV (miles de USD, mediana 21.2) tiene un tope en 50. Lo que más correlaciona con MEDV es LSTAT ($r = -0,74$, con forma curva) y RM (+0,70). Hay atributos muy correlacionados entre sí (RAD–TAX 0,91, NOX–DIS $-0,77$, INDUS–NOX 0,76), así que ya hay multicolinealidad en el modelo lineal. Separamos 80 % para entrenamiento (404) y 20 % para validación (102). El grado y λ se eligen por validación cruzada (CV, 5 *folds* mezclados) sobre entrenamiento, y validación queda como prueba final. Las características se estandarizan dentro de un Pipeline, para que Ridge penalice a todas por igual.




Figura 1: Izquierda: MSE según el grado (color: conjunto; sólido: sin regularizar; punteado: Ridge con su λ^*). Centro: Ridge de grado 2, MSE según λ . Derecha: modelo elegido, predicción contra valor real en validación.

2.2. Características polinomiales.

Subir el grado reduce el error de entrenamiento, pero no el de viviendas nuevas (Tabla 2). Grado 2 ya representa curvas e interacciones, pero sin regularizar mejora en validación y casi nada en CV: depende de qué viviendas le toquen. Grado 3 tiene 559 columnas para 404 viviendas: memoriza los datos y falla por completo en validación. La causa es la multicolinealidad: las columnas casi colineales llevan a coeficientes muy grandes y estos a predicciones inestables.

2.3. Regularización.

Ridge penaliza el tamaño de los coeficientes, y eso vuelve útiles a las características polinomiales. En grado 2 baja el MSE de CV de 23.6 a 15.8 y lo hace más estable entre *folds*. En grado 3, el modelo pasa de inutilizable a competitivo. En el lineal no cambia nada (CV 24.3 con y sin Ridge), porque no hay sobreajuste que corregir. Comparando las gráficas con y sin regularización vimos que las predicciones más alejadas de la diagonal se acercan al utilizar Ridge. Además vimos que con λ chico el modelo sobreajusta y con λ grande predice casi el promedio; el barrido entre 10^{-3} y 10^5 cubre ambos extremos y el óptimo ($\lambda^* \approx 0,87$) queda en el medio.

Cuadro 2: MSE por modelo. CV: promedio $\pm$ desvío en 5 *folds*.

Modelo	Columnas	λ^*	$\ \beta\ $	Entren.	CV	Valid.
Lineal (grado 1)	13	—	7.2	21.6	$24,3 \pm 7,6$	24.3
Grado 2	104	—	302	5.1	$23,6 \pm 8,7$	14.3
Grado 3	559	—	11 726	0.04	$15\,198 \pm 26\,400$	4 988
Ridge grado 1	13	3.91	7.0	21.7	$24,3 \pm 7,9$	24.4
Ridge grado 2	104	0.87	24.4	6.9	$15,8 \pm 5,3$	11.3
Ridge grado 3	559	2.68	14.2	4.5	$18,1 \pm 8,0$	10.4

2.4. Conclusión.

El mejor modelo es el polinomio de grado 2 con Ridge ($\lambda^* \approx 0,87$). Tiene el menor MSE de CV. Ridge de grado 3 da algo menos en validación (10.4 contra 11.3), pero queda peor en CV y usa cinco veces más columnas: preferimos el más simple. Los polinomios mejoran la predicción porque capturan relaciones no lineales como la de LSTAT, pero por sí solos sobreajustan; la regularización convierte esa flexibilidad en mejores predicciones sobre viviendas nuevas. El mayor error está en las 16 viviendas topeadas en 50, cuyo valor real se desconoce.

3. Problema 3: predicción de alturas

3.1. Datos y elección del modelo

Se analizaron 45 respuestas con las alturas del estudiante, de sus padres y el sexo registrado. Se excluyeron dos respuestas incompletas (una sin sexo y otra sin altura del estudiante), quedando 43 casos: 36 masculinos y 7 femeninos.

Las correlaciones estudiante-padre y estudiante-madre fueron 0,203 y 0,180. Se conservaron ambas alturas para evaluar su aporte conjunto y se incluyó el sexo, dadas las medias de 179,17 cm en el grupo masculino y 162,86 cm en el femenino. Se planteó el modelo lineal:

$$y_i = c + a h_{p,i} + b h_{m,i} + d S_i + \varepsilon_i,$$

donde h_p y h_m son las alturas del padre y de la madre en centímetros, y $S = 1$ para Masculino y $S = 0$ para Femenino.

3.2. Estimación de los coeficientes y ecuación final

Los cuatro coeficientes a, b, d, c de la ecuación final se estimaron por mínimos cuadrados con los 43 casos completos, minimizando:

$$\sum_{43 \text{ personas}} [\text{altura real} - (a \cdot \text{altura padre} + b \cdot \text{altura madre} + d \cdot S + c)]^2.$$

Este ajuste produjo la siguiente ecuación, con las alturas expresadas en centímetros:

$$\hat{y} = 56,9971 + 0,2775 h_p + 0,3373 h_m + 17,4370 S.$$

Manteniendo las otras variables iguales, cada centímetro adicional de altura del padre aumenta la predicción en 0,2775 cm, y cada centímetro adicional de altura de la madre, en 0,3373 cm. Para iguales alturas de los padres, la predicción masculina supera a la femenina en 17,4370 cm. El valor 56,9971 es la constante de la ecuación.


3.3. Evaluación del error de predicción

Para evaluar el modelo se utilizó validación cruzada *leave one out*. En cada iteración se excluyó una persona y se estimaron nuevamente los cuatro coeficientes por mínimos cuadrados con las otras 42. Con las alturas de los padres y el sexo de la persona excluida se predijo su altura; su altura real se utilizó después para calcular el error como altura real menos altura predicha.

Se repitió el procedimiento para las 43 personas. Denotando por e_i el error de la persona excluida en la iteración i , el error cuadrático medio (MSE) y su raíz (RMSE) se calcularon como:

$$MSE = \frac{1}{43} \sum_{i=1}^{43} e_i^2 = 21,58 \text{ cm}^2, \quad RMSE = \sqrt{MSE} = 4,65 \text{ cm}.$$

Como referencia, predecir la media de las otras 42 personas produjo un RMSE de 8,01 cm, mayor que el del modelo.



3.4. Conclusiones

El modelo mejoró la predicción respecto a utilizar la media, aunque presenta errores individuales importantes. El RMSE no garantiza un margen de $\pm 4,65$ cm para cada persona. La muestra pequeña, con solo siete casos femeninos, limita la generalización; la precisión debería contrastarse con nuevas observaciones.

Anexo




Figura 2: Simulación de una muestra mediante el método de aceptación-rechazo.




Figura 3: Función de log-verosimilitud negativa y estimación de θ .

Referencias

- [1] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: with Applications in Python*, 2nd ed. Springer, 2021.
- [2] M. E. para la Regresión y la Clasificación, “Notas del curso,” 2023.