

Universidad de la República

Facultad de Ingeniería

Modelos Estadísticos para la clasificación y regresión

Entrega 1 — Obligatorio

Integrantes del grupo

Nombre	Cédula
Facundo Leite	5.185.744-2
Nicolas Martinez	5.432.556-7
Valentina Berón	5.541.264-0

Código del trabajo: <https://github.com/facundo7801/obligatorio1-modest.git>

Profesores:

María Inés Fariello

Gonzalo Cameto

Montevideo, Uruguay

Octubre de 2026

1. Problema 1

1.1. Simulación y estimación

Se considera la densidad

$$f_X(x; \theta) = \frac{1}{2}(1 + \theta x), \quad -1 \leq x, \theta \leq 1,$$

tomando $\theta = -1/3$. Para simular la muestra se utilizó aceptación-rechazo con $g(x) = 1/2$, $x \sim U(-1, 1)$, y $M = 4/3$. Por lo tanto, un candidato se acepta si

$$u \leq \frac{f_X(x)}{Mg(x)} = \frac{3}{4} \left(1 - \frac{x}{3}\right), \quad u \sim U(0, 1).$$

El procedimiento se repite hasta obtener n observaciones aceptadas. Para $n = 10$ se obtuvo, por ejemplo,

$$x = (0,0523, -0,7548, -0,7058, -0,3231, 0,0924, 0,2595, 0,7691, -0,1610, 0,3569, -0,1851).$$

Para una muestra $x_1, \dots, x_n$, la verosimilitud es

$$V_n(\theta) = \frac{1}{2^n} \prod_{i=1}^n (1 + \theta x_i).$$

Se minimizó el negativo del logaritmo de la verosimilitud,

$$\ell_n(\theta) = n \log(2) - \sum_{i=1}^n \log(1 + \theta x_i),$$

en $[-1, 1]$, utilizando el algoritmo *Golden Search*. Para la muestra anterior se obtuvo

$$\hat{\theta} = -0,2964.$$

Se generaron 50 muestras independientes para cada tamaño $n \in 10, 100, 1000$. La tabla muestra la media de $\hat{\theta}$, el sesgo, la varianza y el error cuadrático medio (MSE), tomando $\theta = -1/3$ como valor verdadero.

Cuadro 1: Evaluación del estimador de máxima verosimilitud.

n	θ	$\bar{\hat{\theta}}$	Sesgo	Varianza	MSE
10	-0,3333	-0,2949	0,0384	0,2166	0,2181
100	-0,3333	-0,3369	-0,0036	0,0243	0,0243
1000	-0,3333	-0,3290	0,0044	0,0018	0,0018

Los resultados muestran que, al aumentar n , la varianza y el MSE disminuyen considerablemente, mientras que el sesgo se aproxima a cero. Por lo tanto, las estimaciones se concentran progresivamente alrededor del verdadero valor $\theta = -1/3$.




Figura 1: Simulación mediante aceptación-rechazo.




Figura 2: Log-verosimilitud negativa y estimación.

2. Problema 2: Regresión en el Conjunto de Datos “Boston Housing”

2.1. Datos y método.

El objetivo es predecir el valor mediano de las viviendas (MEDV) a partir de los 13 atributos disponibles, entre ellos CRIM, RM y LSTAT. Son 506 viviendas, 13 atributos y ningún valor faltante. MEDV (miles de USD, mediana 21.2) tiene un tope en 50. Lo que más correlaciona con MEDV es LSTAT ($r = -0,74$, con forma curva) y RM (+0,70). Hay atributos muy correlacionados entre sí (RAD–TAX 0,91, NOX–DIS $-0,77$, INDUS–NOX 0,76), así que ya hay multicolinealidad en el modelo lineal. Separamos 80 % para entrenamiento (404) y 20 % para validación (102). El grado y λ se eligen por validación cruzada (CV, 5 *folds* mezclados) sobre entrenamiento, y validación queda como prueba final. Las características se estandarizan dentro de un Pipeline, para que Ridge penalice a todas por igual.




Figura 3: Izquierda: MSE según el grado (color: conjunto; sólido: sin regularizar; punteado: Ridge con su λ^*). Centro: Ridge de grado 2, MSE según λ . Derecha: modelo elegido, predicción contra valor real en validación.

2.2. Características polinomiales.

Subir el grado reduce el error de entrenamiento, pero no el de viviendas nuevas (Tabla 2). Grado 2 ya representa curvas e interacciones, pero sin regularizar mejora en validación y casi nada en CV: depende de qué viviendas le toquen. Grado 3 tiene 559 columnas para 404 viviendas: memoriza los datos y falla por completo en validación. La causa es la multicolinealidad: las columnas casi colineales llevan a coeficientes muy grandes y estos a predicciones inestables.

2.3. Regularización.

Ridge penaliza el tamaño de los coeficientes, y eso vuelve útiles a las características polinomiales. En grado 2 baja el MSE de CV de 23.6 a 15.8 y lo hace más estable entre *folds*. En grado 3, el modelo pasa de inutilizable a competitivo. En el lineal no cambia nada (CV 24.3 con y sin Ridge), porque no hay sobreajuste que corregir. Comparando las gráficas con y sin regularización vimos que las predicciones más alejadas de la diagonal se acercan al utilizar Ridge. Además vimos que con λ chico el modelo sobreajusta y con λ grande predice casi el promedio; el barrido entre 10^{-3} y 10^5 cubre ambos extremos y el óptimo ($\lambda^* \approx 0,87$) queda en el medio.

Cuadro 2: MSE por modelo. CV: promedio $\pm$ desvío en 5 *folds*.

Modelo	Columnas	λ^*	$\ \beta\ $	Entren.	CV	Valid.
Lineal (grado 1)	13	—	7.2	21.6	$24,3 \pm 7,6$	24.3
Grado 2	104	—	302	5.1	$23,6 \pm 8,7$	14.3
Grado 3	559	—	11 726	0.04	$15\,198 \pm 26\,400$	4 988
Ridge grado 1	13	3.91	7.0	21.7	$24,3 \pm 7,9$	24.4
Ridge grado 2	104	0.87	24.4	6.9	$15,8 \pm 5,3$	11.3
Ridge grado 3	559	2.68	14.2	4.5	$18,1 \pm 8,0$	10.4

2.4. Conclusión.

El mejor modelo es el polinomio de grado 2 con Ridge ($\lambda^* \approx 0,87$). Tiene el menor MSE de CV. Ridge de grado 3 da algo menos en validación (10.4 contra 11.3), pero queda peor en CV y usa cinco veces más columnas: preferimos el más simple. Los polinomios mejoran la predicción porque capturan relaciones no lineales como la de LSTAT, pero por sí solos sobreajustan; la regularización convierte esa flexibilidad en mejores predicciones sobre viviendas nuevas. El mayor error está en las 16 viviendas topeadas en 50, cuyo valor real se desconoce.

3. Problema 3: predicción de alturas

3.1. Datos y elección del modelo

Se analizaron 45 respuestas con las alturas del estudiante, de sus padres y el sexo registrado. Se excluyeron dos respuestas incompletas (una sin sexo y otra sin altura del estudiante), quedando 43 casos: 36 masculinos y 7 femeninos.

Las correlaciones estudiante-padre y estudiante-madre fueron 0,203 y 0,180. Se conservaron ambas alturas para evaluar su aporte conjunto y se incluyó el sexo, dadas las medias de 179,17 cm en el grupo masculino y 162,86 cm en el femenino. Se planteó el modelo lineal:

$$y_i = c + a h_{p,i} + b h_{m,i} + d S_i + \varepsilon_i,$$

donde h_p y h_m son las alturas del padre y de la madre en centímetros, y $S = 1$ para Masculino y $S = 0$ para Femenino.

3.2. Estimación de los coeficientes y ecuación final

Los cuatro coeficientes a, b, d, c de la ecuación final se estimaron por mínimos cuadrados con los 43 casos completos, minimizando:

$$\sum_{43 \text{ personas}} [\text{altura real} - (a \cdot \text{altura padre} + b \cdot \text{altura madre} + d \cdot S + c)]^2.$$

Este ajuste produjo la siguiente ecuación, con las alturas expresadas en centímetros:

$$\hat{y} = 56,9971 + 0,2775 h_p + 0,3373 h_m + 17,4370 S.$$

Manteniendo las otras variables iguales, cada centímetro adicional de altura del padre aumenta la predicción en 0,2775 cm, y cada centímetro adicional de altura de la madre, en 0,3373 cm. Para iguales alturas de los padres, la predicción masculina supera a la femenina en 17,4370 cm. El valor 56,9971 es la constante de la ecuación.


3.3. Evaluación del error de predicción

Para evaluar el modelo se utilizó validación cruzada *leave one out*. En cada iteración se excluyó una persona y se estimaron nuevamente los cuatro coeficientes por mínimos cuadrados con las otras 42. Con las alturas de los padres y el sexo de la persona excluida se predijo su altura; su altura real se utilizó después para calcular el error como altura real menos altura predicha.

Se repitió el procedimiento para las 43 personas. Denotando por e_i el error de la persona excluida en la iteración i , el error cuadrático medio (MSE) y su raíz (RMSE) se calcularon como:

$$MSE = \frac{1}{43} \sum_{i=1}^{43} e_i^2 = 21,58 \text{ cm}^2, \quad RMSE = \sqrt{MSE} = 4,65 \text{ cm}.$$

Como referencia, predecir la media de las otras 42 personas produjo un RMSE de 8,01 cm, mayor que el del modelo.



3.4. Conclusiones

El modelo mejoró la predicción respecto a utilizar la media, aunque presenta errores individuales importantes. El RMSE no garantiza un margen de $\pm 4,65$ cm para cada persona. La muestra pequeña, con solo siete casos femeninos, limita la generalización; la precisión debería contrastarse con nuevas observaciones.

Anexo




Figura 4: Simulación de una muestra mediante el método de aceptación-rechazo.




Figura 5: Función de log-verosimilitud negativa y estimación de θ .

Referencias

- [1] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: with Applications in Python*, 2nd ed. Springer, 2021.
- [2] M. E. para la Regresión y la Clasificación, “Notas del curso,” 2023.