

Universidad de la República

Facultad de Ingeniería

Modelos Estadísticos para la clasificación y regresión

Entrega 1 — Obligatorio

Integrantes del grupo

Nombre	Cédula
Facundo Leite	5.185.744-2
Nicolas Martinez	5.432.556-7
Nombre Apellido 3	00.000.000-0

Código del trabajo: <https://github.com/facundo7801/obligatorio1-modest.git>

Profesores:

María Inés Fariello

Gonzalo Cameto

Montevideo, Uruguay

Octubre de 2026

1. Problema 1

1.1. Simulación de una muestra

Se considera la densidad

$$f_X(x; \theta) = \frac{1}{2}(1 + \theta x), \quad -1 \leq x \leq 1, \quad -1 \leq \theta \leq 1,$$

y se desea simular una muestra tomando $\theta = -1/3$. En este caso,

$$f_X(x) = \frac{1}{2} \left(1 - \frac{x}{3}\right).$$

Para generar la muestra se utilizó el método de aceptación-rechazo, tomando como densidad propuesta una distribución uniforme en $[-1, 1]$:

$$g(x) = \frac{1}{2}.$$

La constante utilizada es $M = 4/3$, por lo que un candidato $x \sim U(-1, 1)$ se acepta si

$$u \leq \frac{f_X(x)}{Mg(x)} = \frac{3}{4} \left(1 - \frac{x}{3}\right), \quad u \sim U(0, 1).$$

El procedimiento se repite hasta obtener n observaciones aceptadas.

Para una muestra de tamaño 10 se obtuvo, por ejemplo,

$$x = (0,0523, -0,7548, -0,7058, -0,3231, 0,0924, 0,2595, \\ 0,7691, -0,1610, 0,3569, -0,1851).$$

1.2. Estimador de máxima verosimilitud

Para una muestra $x_1, \dots, x_n$, la función de verosimilitud es

$$V_n(\theta) = \prod_{i=1}^n f_X(x_i; \theta) = \frac{1}{2^n} \prod_{i=1}^n (1 + \theta x_i).$$

Para evitar trabajar directamente con el producto se utilizó el negativo del logaritmo de la verosimilitud:

$$\ell_n(\theta) = -\log V_n(\theta) = n \log(2) - \sum_{i=1}^n \log(1 + \theta x_i).$$

El estimador de máxima verosimilitud se obtiene minimizando esta función en $[-1, 1]$:

$$\hat{\theta} = \arg \min_{-1 \leq \theta \leq 1} \ell_n(\theta).$$

Para realizar la minimización numérica se utilizó el algoritmo de *Golden Search*.

Para la muestra de tamaño 10 obtenida anteriormente se obtuvo

$$\hat{\theta} = -0,2964.$$

1.3. Evaluación del estimador para muestras de tamaño 10

Se generaron 50 muestras independientes de tamaño 10. Para cada muestra se calculó el estimador $\hat{\theta}$ mediante el procedimiento anterior.

Tomando como valor verdadero $\theta = -1/3$, SE, el sesgo y la varianza:

Los resultados obtenidos fueron:

Cuadro 1: Resultados para muestras de tamaño 10.

Cantidad	Tamaño	θ verdadero	$\bar{\hat{\theta}}$	Sesgo	Varianza	MSE
50	10	-0,3333	-0,2949	0,0384	0,2166	0,2181
50	100	-0,3333	-0,3369	-0,0036	0,0243	0,0243
50	1000	-0,3333	-0,3290	0,0044	0,0018	0,0018

Al aumentar el tamaño de la muestra, se observa una disminución considerable de la varianza del estimador y, en consecuencia, del MSE. Además, el sesgo se aproxima a cero. Esto indica que las estimaciones de $\hat{\theta}$ se concentran cada vez más alrededor del verdadero valor $\theta = -1/3$. Para $n = 100$ y $n = 1000$, el término Sesgo² es muy pequeño, por lo que el MSE coincide con la varianza al redondear a cuatro decimales.

3. Problema 3: predicción de alturas

3.1. Datos y elección del modelo

Se analizaron 45 respuestas con las alturas del estudiante, de sus padres y el sexo registrado. Se excluyeron dos respuestas incompletas (una sin sexo y otra sin altura del estudiante), quedando 43 casos: 36 masculinos y 7 femeninos.

Las correlaciones estudiante-padre y estudiante-madre fueron 0,203 y 0,180. Se conservaron ambas alturas para evaluar su aporte conjunto y se incluyó el sexo, dadas las medias de 179,17 cm en el grupo masculino y 162,86 cm en el femenino. Se planteó el modelo lineal:

$$y_i = c + a h_{p,i} + b h_{m,i} + d S_i + \varepsilon_i,$$

donde h_p y h_m son las alturas del padre y de la madre en centímetros, y $S = 1$ para Masculino y $S = 0$ para Femenino.

3.2. Estimación de los coeficientes y ecuación final

Los cuatro coeficientes a, b, d, c de la ecuación final se estimaron por mínimos cuadrados con los 43 casos completos, minimizando:

$$\sum_{43 \text{ personas}} [\text{altura real} - (a \cdot \text{altura padre} + b \cdot \text{altura madre} + d \cdot S + c)]^2.$$

Este ajuste produjo la siguiente ecuación, con las alturas expresadas en centímetros:

$$\hat{y} = 56,9971 + 0,2775 h_p + 0,3373 h_m + 17,4370 S.$$

Manteniendo las otras variables iguales, cada centímetro adicional de altura del padre aumenta la predicción en 0,2775 cm, y cada centímetro adicional de altura de la madre, en 0,3373 cm. Para iguales alturas de los padres, la predicción masculina supera a la femenina en 17,4370 cm. El valor 56,9971 es la constante de la ecuación.


3.3. Evaluación del error de predicción

Para evaluar el modelo se utilizó validación cruzada *leave one out*. En cada iteración se excluyó una persona y se estimaron nuevamente los cuatro coeficientes por mínimos cuadrados con las otras 42. Con las alturas de los padres y el sexo de la persona excluida se predijo su altura; su altura real se utilizó después para calcular el error como altura real menos altura predicha.

Se repitió el procedimiento para las 43 personas. Denotando por e_i el error de la persona excluida en la iteración i , el error cuadrático medio (MSE) y su raíz (RMSE) se calcularon como:

$$MSE = \frac{1}{43} \sum_{i=1}^{43} e_i^2 = 21,58 \text{ cm}^2, \quad RMSE = \sqrt{MSE} = 4,65 \text{ cm}.$$

Como referencia, predecir la media de las otras 42 personas produjo un RMSE de 8,01 cm, mayor que el del modelo.



3.4. Conclusiones

El modelo mejoró la predicción respecto a utilizar la media, aunque presenta errores individuales importantes. El RMSE no garantiza un margen de $\pm 4,65$ cm para cada persona. La muestra pequeña, con solo siete casos femeninos, limita la generalización; la precisión debería contrastarse con nuevas observaciones.

Anexo




Figura 1: Simulación de una muestra mediante el método de aceptación-rechazo.




Figura 2: Función de log-verosimilitud negativa y estimación de θ .

Referencias

- [1] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: with Applications in Python*, 2nd ed. Springer, 2021.
- [2] M. E. para la Regresión y la Clasificación, “Notas del curso,” 2023.